

Índice

1. ACF, PACF y densidad espectral teóricas	2
1.1. Ruido blanco	2
2. ACF, PACF y densidad espectral estimadas de un modelo simulado	2
2.1. Ruido blanco	2
3. Análisis de un modelo ARMA	3
3.1. ACF, PACF y densidad espectral teóricas	3
3.2. Simulación del modelo, estimación de las ACF y PACF muestrales y cálculo del periodograma	3
3.2.1. Caso paseo aleatorio	3
3.2.2. Caso ARMA estacional	3
3.3. Raíces de uno de los polinomios	4
4. Ejemplo de uso	4
5. Código en python	4
5.1. Cálculo de la PACF a partir de la ACF (<code>theoretical_pacf_from_acf</code>)	5
5.2. Representación de la ACF, PACF y densidad espectral teóricas (<code>plot_arma_parametric_</code> <code>diagnostics</code>)	5
5.3. Simulación y análisis de un modelo ARMA (<code>plot_arma_analysis</code>)	10
5.3.1. Caso paseo aleatorio	12
5.4. Análisis de las raíces de un polinomio (<code>polynomial_roots_table</code>)	14
5.5. Análisis de las raíces de un polinomio (<code>Localizacion_parametros_plot</code>)	15
5.6. Conversión de un polinomio B^s en un polinomio en B	16
5.7. Gráfico región parámetros polinomio grado 2 (<code>RegionParametrica</code>)	16
5.8. Gráfico rango mediana (<code>RangoMediana</code>)	18

Análisis y Visualización de Procesos Estocásticos ARMA: ACF, PACF y Espectros

Marcos Bujosa

25 de octubre de 2025

Al final del documento aparece el código fuente de algunos programas que usaré para crear el material de clase correspondiente al análisis de modelos ARMA.

Veamos algunos ejemplos de lo que obtenemos con dichos programas:

```
import warnings
warnings.filterwarnings("ignore", category=UserWarning)
%run -i analisis_armas.py
```

1. ACF, PACF y densidad espectral teóricas

1.1. Ruido blanco

```
ar_params = [1,]
ma_params = [1,]
plot_arma_parametric_diagnostics(ar_params, ma_params)
```

<Figure size 1800x300 with 3 Axes>

2. ACF, PACF y densidad espectral estimadas de un modelo simulado

2.1. Ruido blanco

```
plot_arma_analysis(ar_params, ma_params, seed=2026)
```

<Figure size 1800x700 with 4 Axes>

3. Análisis de un modelo ARMA

3.1. ACF, PACF y densidad espectral teóricas

```
ar_params = [1, 0.5]
ma_params = [1, -0.9, 0.4]
plot_arma_parametric_diagnostics(ar_params, ma_params)
```

<Figure size 1800x300 with 3 Axes>

3.2. Simulación del modelo, estimación de las ACF y PACF muestrales y cálculo del periodograma

```
plot_arma_analysis(ar_params, ma_params)
```

<Figure size 1800x700 with 4 Axes>

3.2.1. Caso paseo aleatorio

Paseo aleatorio con deriva

```
plot_paseo_aleatorio_analysis(trend="t", pendiente=0.25, n=400, semilla=2025)
```

<Figure size 1800x700 with 4 Axes>

Paseo aleatorio sin deriva

```
plot_paseo_aleatorio_analysis(n=400, semilla=2026)
```

<Figure size 1800x700 with 4 Axes>

3.2.2. Caso ARMA estacional

```
plot_arma_seasonal_parametric_diagnostics(ar_params=[1, -0.9], s=12, seasonal_ar_params=[1, -0.9], logs=True)
```

<Figure size 1800x300 with 3 Axes>

```
plot_arma_seasonal_parametric_diagnostics(seasonal_ma_params=[1, -0.9])
```

<Figure size 1800x300 with 3 Axes>

3.3. Raíces de uno de los polinomios

```
ar_params = [1, -0.9, 0.4]
polynomial_roots_table(ar_params)
```

```
plot_arma_analysis(ar_params, ma_params)
```

<Figure size 1800x700 with 4 Axes>

4. Ejemplo de uso

```
ma_params = [1, -1.5, 0.54]
#ma_params = [1, -1, 0.25]
#ma_params = [1, -1, 0.35]
#ma_params = [1, -1, 0]
#ma_params = [1, 0, 1]

polynomial_roots_table(ma_params)
```

```
Localizacion_parametros_plot(-ma_params[1],-ma_params[2], 'AR')
```

<Figure size 1000x600 with 1 Axes>

```
plot_arma_parametric_diagnostics([1], ma_params)
```

<Figure size 1800x300 with 3 Axes>

```
plot_sarima_analysis(seasonal_ar_params=[1,],d=0, ar_params=[1,],D=1,s=12,n=300)
```

<Figure size 1800x700 with 4 Axes>

5. Código en python

Éstas son las librerías empleadas en las funciones de más abajo:

```
import numpy as np
from numpy.polynomial import Polynomial

import pandas as pd

import matplotlib as mpl
# definimos parámetros para mejorar los gráficos
mpl.rc('text', usetex=False)
import matplotlib.pyplot as plt
```

```

import matplotlib.ticker as ticker ## *** nuevo para ARMAs estacionales

import statsmodels.api as sm
from statsmodels.tsa.arima_process import ArmaProcess
from statsmodels.tsa.arima.model import ARIMA ## *** nuevo en paseos aleatorios

from scipy import signal
from scipy.signal import freqz

import math

```

5.1. Cálculo de la PACF a partir de la ACF (theoretical_pacf_from_acf)

La siguiente función calcula la PACF a partir de la ACF resolviendo las [ecuaciones de Yule-Walker](#) recursivamente con el algoritmo [Levinson-Durbin](#); véase *Pourahmadi, M. (2001, Capítulo 7)* o *Brockwell & Davis (1991, Capítulo 5)*).

```

def theoretical_pacf_from_acf(acf_vals):
    """
    Calcula la PACF teórica (para lags >= 0) de forma paramétrica usando el algoritmo de Durbin-Levinson.

    Parámetros:
        acf_vals (list):
            una lista tal que acf_vals[0] corresponde al retardo 0.

    Retorna:
        list: el coeficiente en la posición k corresponde a la PACF en el retardo k.
    """
    nlags = len(acf_vals)-1
    # Matriz para almacenar los coeficientes (phi)
    phi = np.zeros((nlags+1, nlags+1))
    # v guarda la varianza de error en cada paso
    v = np.zeros(nlags+1)
    pacf = np.zeros(nlags+1)
    v[0] = acf_vals[0]
    pacf[0] = 1.0 # Por convención, PACF(0)=1.

    for k in range(1, nlags+1):
        if k == 1:
            phi[1,1] = acf_vals[1] / acf_vals[0]
            pacf[1] = phi[1,1]
            v[1] = v[0]*(1 - phi[1,1]**2)
        else:
            sum_val = 0.0
            # Sumar phi[k-1,j]*acf_vals[k-j] para j=1,...,k-1.
            for j in range(1, k):
                sum_val += phi[k-1, j] * acf_vals[k - j]
            phi[k, k] = (acf_vals[k] - sum_val) / v[k-1]
            pacf[k] = phi[k, k]
            for j in range(1, k):
                phi[k, j] = phi[k-1, j] - phi[k, k] * phi[k-1, k - j]
            v[k] = v[k-1] * (1 - phi[k, k]**2)
    return pacf # Incluye PACF en lag 0 con valor 1.

```

5.2. Representación de la ACF, PACF y densidad espectral teóricas (plot_arma_parametric_diagnostics)

La siguiente función pinta las ACF, PACF y densidad espectral teóricas de un modelo ARMA.

```

def plot_arma_parametric_diagnostics(ar_params=[1,], ma_params=[1,], sigma2=1, lags=False):
    """
    Genera y retorna una figura con tres subgráficas para un modelo ARMA:
    - ACF teórica (omitiendo retardo 0)
    - PACF teórica paramétrica (calculada vía el algoritmo de Durbin-Levinson, omitiendo retardo 0)
    - Densidad espectral teórica

    Parámetros:
    ar_params (list):
        Coeficientes del polinomio AR (debe incluir el 1 inicial).
    ma_params (list):
        Coeficientes del polinomio MA (debe incluir el 1 inicial).
    sigma2 (float):
        Varianza del ruido U.
    lags (int, opcional):
        Número de retardos considerados (por defecto 20).

    Retorna:
    fig : objeto matplotlib.figure.Figure
    """

    phi = Polynomial(ar_params, symbol='B')
    theta = Polynomial(ma_params, symbol='B')
    # Crear el proceso ARMA
    arma_process = ArmaProcess(ar=phi.coef, ma=theta.coef)

    s=4
    if lags:
        lags=lags
    else:
        lags=(s*5)+1

    # 1. Calcular la ACF teórica
    acf_theo = arma_process.acf(lags=lags)
    lags_theo = np.arange(len(acf_theo))
    # Omitir el retardo 0 para gráficos de ACF y PACF:
    acf_plot = acf_theo[1:]
    lags_plot = lags_theo[1:]

    # 2. Calcular la PACF teórica de forma paramétrica a partir de la ACF
    pacf_theo = theoretical_pacf_from_acf(acf_theo)
    pacf_plot = pacf_theo[1:]
    lags_pacf = np.arange(len(pacf_theo))[1:]

    # 3. Calcular la densidad espectral teórica usando freqz
    w, h = freqz(theta.coef, phi.coef, worN=1024)
    freq = w / (2 * np.pi) # Conversión de radianes/muestra a ciclos/muestra
    spectrum = (sigma2 / (2 * np.pi)) * np.abs(h)**2

    # 4. Graficar los tres subgráficos
    s=5
    lags=False
    fig, axs = plt.subplots(1, 3, figsize=(18, 3))

    # ACF teórica
    axs[0].stem(lags_plot, acf_plot, basefmt=" ")
    axs[0].axhline(0, color='black', lw=0.5, linestyle='--')
    axs[0].set_xlabel('Retardo')
    axs[0].set_ylabel('ACF')
    axs[0].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
    axs[0].grid(axis='x') # Añadir cuadrícula vertical

    # PACF teórica paramétrica
    axs[1].stem(lags_pacf, pacf_plot, basefmt=" ")

```

```

axs[1].axhline(0, color='black', lw=0.5, linestyle='--')
axs[1].set_xlabel('Retardo')
axs[1].set_ylabel('PACF')
axs[1].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
axs[1].grid(axis='x') # Añadir cuadrícula vertical

# Densidad espectral teórica
axs[2].plot(freq, spectrum)
axs[2].axhline(0, color='black', lw=0.5, linestyle='--')
axs[2].set_xlabel('Frecuencia')

if logs:
    axs[2].set_yscale('log')
    axs[2].set_ylabel('Log. Densidad Espectral')
else:
    axs[2].set_ylabel('Densidad Espectral')

plt.tight_layout()
plt.close(fig)
return fig

```

Breve explicación de la anterior función `plot_arma_parametric_diagnostics`:

1. La función recibe los parámetros del modelo ARMA y el número de retardos.
2. Se calcula la ACF teórica y a partir de ella la PACF con `theoretical_pacf_from_acf`; en la gráfica se omite el retardo cero.
3. La densidad espectral teórica $S(\omega)$ se obtiene mediante la función `freqz` y la fórmula

$$S(\omega) = \frac{\sigma^2}{2\pi} \left| \frac{\sum_{j=0}^q \theta_j e^{-i2\pi\omega j}}{\sum_{k=0}^p \phi_k e^{-i2\pi\omega k}} \right|^2.$$

Donde:

- σ^2 es la varianza del término de error (innovación) del modelo.
- $(\theta_j \mid j = 0 : q)$ son los coeficientes del polinomio de medias móviles (MA), de modo que el polinomio MA es: $\theta(z) = \sum_{j=0}^q \theta_j z^j$.
- $(\phi_k \mid k = 0 : p)$ son los coeficientes del polinomio autorregresivo (AR), de modo que el polinomio AR es: $\phi(z) = \sum_{k=0}^p \phi_k z^k$.
- Al evaluar estos polinomios en $z = e^{-i2\pi\omega}$ se obtiene la respuesta en frecuencia del modelo:

$$H(e^{-i2\pi\omega}) = \frac{\theta(e^{-i2\pi\omega})}{\phi(e^{-i2\pi\omega})}.$$

- El módulo al cuadrado de $H(e^{-i2\pi\omega})$ multiplicado por $\frac{\sigma^2}{2\pi}$ es la densidad espectral.

Esta fórmula es fundamental porque permite conocer la distribución de la varianza del proceso a lo largo de las diferentes frecuencias, lo cual es clave para analizar las propiedades dinámicas en modelos ARMA.

4. Se crean tres subgráficos, y se añade una línea horizontal en $y=0$ en cada uno (`axhline`).

5. Por último, la función retorna el objeto figura.

```
def plot_arma_seasonal_parametric_diagnostics(ar_params=[1,], ma_params=[1,], s=5, seasonal_ar_params=[1,], seasonal_ma_params=[1,])
    """
    Genera y retorna una figura con tres subgráficas para un modelo ARMA estacional:
    - ACF teórica (omitiendo retardo 0)
    - PACF teórica paramétrica (calculada vía el algoritmo de Durbin-Levinson, omitiendo retardo 0)
    - Densidad espectral teórica

    Parámetros:
    ar_params (list):
        Coeficientes del polinomio AR en B (debe incluir el 1 inicial).
    ma_params (list):
        Coeficientes del polinomio MA en B (debe incluir el 1 inicial).
    seasonal_ar_params (list):
        Coeficientes del polinomio AR estacional en B~s (debe incluir el 1 inicial).
    seasonal_ma_params (list):
        Coeficientes del polinomio MA estacional en B~s (debe incluir el 1 inicial).
    sigma2 (float):
        Varianza del ruido U.
    lags (int, opcional):
        Número de retardos considerados (por defecto 20).
    seasonal_lags (int, opcional):
        Número de retardos estacionales (por defecto 0).

    Retorna:
    fig : objeto matplotlib.figure.Figure
    """

    if lags:
        lags=lags
    else:
        lags=(s*5)+2

    # Definir los polinomios AR y MA (incluyendo componentes estacionales)
    phi_r = Polynomial(ar_params, symbol='B')
    theta_r = Polynomial(ma_params, symbol='B')
    phi_s = Seasonal_to_regular_polynomial(seasonal_ar_params, s)
    theta_s = Seasonal_to_regular_polynomial(seasonal_ma_params, s)

    phi = phi_r*phi_s
    theta = theta_r*theta_s

    # Crear el proceso ARMA estacional
    arma_process = ArmaProcess(ar=phi.coef, ma=theta.coef)

    # 1. Calcular la ACF teórica
    acf_theo = arma_process.acf(lags=lags)
    lags_theo = np.arange(len(acf_theo))
    # Omitir el retardo 0 para gráficos de ACF y PACF:
    acf_plot = acf_theo[1:]
    lags_plot = lags_theo[1:]

    # 2. Calcular la PACF teórica de forma paramétrica a partir de la ACF
    pacf_theo = theoretical_pacf_from_acf(acf_theo)
    pacf_plot = pacf_theo[1:]
    lags_pacf = np.arange(len(pacf_theo))[1:]

    # 3. Calcular la densidad espectral teórica usando freqz
    w, h = freqz(theta.coef, phi.coef, worN=1024)
    freq = w / (2 * np.pi) # Conversión de radianes/muestra a ciclos/muestra
    spectrum = (sigma2 / (2 * np.pi)) * np.abs(h)**2

    # 4. Graficar los tres subgráficos
```



```

fig, axs = plt.subplots(1, 3, figsize=(18, 3))

# ACF teórica
axs[0].stem(lags_plot, acf_plot, basefmt=" ")
axs[0].axhline(0, color='black', lw=0.5, linestyle='--')
axs[0].set_xlabel('Retardo')
axs[0].set_ylabel('ACF')
axs[0].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
axs[0].grid(axis='x') # Añadir cuadrícula vertical

# PACF teórica paramétrica
axs[1].stem(lags_pacf, pacf_plot, basefmt=" ")
axs[1].axhline(0, color='black', lw=0.5, linestyle='--')
axs[1].set_xlabel('Retardo')
axs[1].set_ylabel('PACF')
axs[1].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
axs[1].grid(axis='x') # Añadir cuadrícula vertical

# Densidad espectral teórica
axs[2].plot(freq, spectrum)
axs[2].axhline(0, color='black', lw=0.5, linestyle='--')
axs[2].set_xlabel('Frecuencia')

if logs:
    axs[2].set_yscale('log')
    axs[2].set_ylabel('Log. Densidad Espectral')
else:
    axs[2].set_ylabel('Densidad Espectral')

plt.tight_layout()
plt.close(fig)
return fig

```

```

fig, axs = plt.subplots(1, 3, figsize=(18, 3))

# ACF teórica
axs[0].stem(lags_plot, acf_plot, basefmt=" ")
axs[0].axhline(0, color='black', lw=0.5, linestyle='--')
axs[0].set_xlabel('Retardo')
axs[0].set_ylabel('ACF')
axs[0].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
axs[0].grid(axis='x') # Añadir cuadrícula vertical

# PACF teórica paramétrica
axs[1].stem(lags_pacf, pacf_plot, basefmt=" ")
axs[1].axhline(0, color='black', lw=0.5, linestyle='--')
axs[1].set_xlabel('Retardo')
axs[1].set_ylabel('PACF')
axs[1].xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
axs[1].grid(axis='x') # Añadir cuadrícula vertical

# Densidad espectral teórica
axs[2].plot(freq, spectrum)
axs[2].axhline(0, color='black', lw=0.5, linestyle='--')
axs[2].set_xlabel('Frecuencia')

if logs:
    axs[2].set_yscale('log')
    axs[2].set_ylabel('Log. Densidad Espectral')
else:
    axs[2].set_ylabel('Densidad Espectral')

```

```

def SARIMA2ARMA(ar_params=[1,], ma_params=[1,], d=0, s=4, seasonal_ar_params=[1,], seasonal_ma_params=[1,], D=0):
    """
    Devuelve los coeficientes de los polinomios AR y MA en B con todas las raíces del modelo.
    """

    # Definir los polinomios AR y MA (incluyendo componentes estacionales y raíces unitarias)
    phi_r = Polynomial(ar_params, symbol='B')
    theta_r = Polynomial(ma_params, symbol='B')
    I_r = Polynomial([1, -1], symbol='B')**d
    phi_s = Seasonal_to_regular_polynomial(seasonal_ar_params, s)
    theta_s = Seasonal_to_regular_polynomial(seasonal_ma_params, s)
    I_s = Seasonal_to_regular_polynomial([1, -1], s)**D

    phi = phi_r*phi_s*I_r*I_s
    theta = theta_r*theta_s
    return phi.coef, theta.coef

```

5.3. Simulación y análisis de un modelo ARMA (plot_arma_analysis)

Función que simula un modelo ARIMA y pinta la serie temporal, las ACF, PACF y densidad espectral estimadas con los datos simulados.

```

def plot_arma_analysis(ar_params=[1,], ma_params=[1,], sigma2=1, lags=20, n=400, seed=None):
    """
    Simula una serie temporal utilizando un modelo ARMA y visualiza la serie generada junto con sus funciones de autocorrelación

    Parameters
    -----
    ar_params : list, optional
        Coeficientes AR del modelo (por defecto [1]).
    ma_params : list, optional
        Coeficientes MA del modelo (por defecto [1]).
    sigma2 : float, optional
        Varianza del ruido blanco (por defecto 1).
    lags : int, optional
        Número de lags a incluir en ACF y PACF (por defecto 20).
    n : int, optional
        Número de observaciones a simular (por defecto 400).
    seed : int, optional
        Semilla para la generación aleatoria (por defecto 0).

    Returns
    -----
    fig : matplotlib.figure.Figure
        La figura generada que incluye la serie temporal y los gráficos ACF, PACF y el periodograma.
    """

    lags=math.floor(n/2) if n/2 < lags else lags

    phi = Polynomial(ar_params, symbol='B')
    theta = Polynomial(ma_params, symbol='B')
    arma_process = sm.tsa.ArmaProcess(phi.coef, theta.coef)

    # Simulación de la serie temporal
    if seed:
        np.random.seed(seed)
    data = arma_process.generate_sample(nsample=n)

    s=5
    # Crear la figura

```

```

fig = plt.figure(figsize=(18, 7))

# Subgráfico de la serie temporal
ax1 = fig.add_subplot(2, 1, 1)
ax1.plot(data, color='blue')
ax1.set_title('Serie Temporal Simulada')
ax1.set_xlabel('t')

# Crear una fila de 3 subgráficos para ACF, PACF y periodograma
ax2 = fig.add_subplot(2, 3, 4) # Fila 2, Columna 1
sm.graphics.tsa.plot_acf(data, lags=lags, ax=ax2, title='ACF Estimada', zero=False, auto_ylimits=True)
ax2.set_xlabel('Retardo')
ax2.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax2.grid(axis='x') # Añadir cuadrícula vertical

ax3 = fig.add_subplot(2, 3, 5) # Fila 2, Columna 2
sm.graphics.tsa.plot_pacf(data, lags=lags, ax=ax3, title='PACF Estimada', zero=False, auto_ylimits=True)
ax3.set_xlabel('Retardo')
ax3.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax3.grid(axis='x') # Añadir cuadrícula vertical

ax4 = fig.add_subplot(2, 3, 6) # Fila 2, Columna 3
f, Pxx = signal.welch(data, fs=1, nperseg=256)
ax4.plot(f, Pxx, color='purple')
ax4.set_title('Periodograma Estimado')
ax4.set_xlabel('Frecuencia')
ax4.set_xlim(0, 0.5) # Limitar el eje x a 0.5

plt.tight_layout()
plt.close(fig)
return fig

```

```

def plot_sarima_analysis(ar_params=[1,], ma_params=[1,], d=0, s=4, seasonal_ar_params=[1,], seasonal_ma_params=[1,], D=0, sigma2=1):
    """
    Simula una serie temporal utilizando un modelo ARMA y visualiza la serie generada junto con sus funciones de autocorrelación.

    Parameters
    -----
    ar_params : list, optional
        Coeficientes AR del modelo (por defecto [1]).
    ma_params : list, optional
        Coeficientes MA del modelo (por defecto [1]).
    sigma2 : float, optional
        Varianza del ruido blanco (por defecto 1).
    lags : int, optional
        Número de lags a incluir en ACF y PACF (por defecto 20).
    n : int, optional
        Número de observaciones a simular (por defecto 400).
    seed : int, optional
        Semilla para la generación aleatoria (por defecto 0).

    Returns
    -----
    fig : matplotlib.figure.Figure
        La figura generada que incluye la serie temporal y los gráficos ACF, PACF y el periodograma.
    """
    phi, theta = SARIMA2ARMA(ar_params=ar_params, ma_params=ma_params, d=d, s=s, seasonal_ar_params=seasonal_ar_params, seasonal_ma_params=seasonal_ma_params)
    arma_process = sm.tsa.ArmaProcess(phi, theta)

    # Simulación de la serie temporal
    if seed:
        np.random.seed(seed)

```

```

data = arma_process.generate_sample(nsamples=n)

if lags:
    lags=lags
else:
    lags=(s*5)+1

lags=math.floor(n/2) if n/2 < lags else lags

# Crear la figura
fig = plt.figure(figsize=(18, 7))

# Subgráfico de la serie temporal
ax1 = fig.add_subplot(2, 1, 1)
ax1.plot(data, color='blue')
ax1.set_title('Serie Temporal Simulada')
ax1.set_xlabel('t')

# Crear una fila de 3 subgráficos para ACF, PACF y periodograma
ax2 = fig.add_subplot(2, 3, 4) # Fila 2, Columna 1
sm.graphics.tsa.plot_acf(data, lags=lags, ax=ax2, title='ACF Estimada', zero=False, auto_ylims=True)
ax2.set_xlabel('Retardo')
ax2.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax2.grid(axis='x') # Añadir cuadrícula vertical

ax3 = fig.add_subplot(2, 3, 5) # Fila 2, Columna 2
sm.graphics.tsa.plot_pacf(data, lags=lags, ax=ax3, title='PACF Estimada', zero=False, auto_ylims=True)
ax3.set_xlabel('Retardo')
ax3.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax3.grid(axis='x') # Añadir cuadrícula vertical

ax4 = fig.add_subplot(2, 3, 6) # Fila 2, Columna 3
f, Pxx = signal.welch(data, fs=1, nperseg=256)
ax4.plot(f, Pxx, color='purple')
ax4.set_title('Periodograma Estimado')
ax4.set_xlabel('Frecuencia')
ax4.set_xlim(0, 0.5) # Limitar el eje x a 0.5

plt.tight_layout()
plt.close(fig)
return fig

```

5.3.1. Caso paseo aleatorio

```

def plot_paseo_aleatorio_analysis(sigma2=1, lags=20, n=400, semilla=None, trend="n", pendiente=0):
    # Simulación de la serie temporal
    transitorio = 50
    if semilla:
        np.random.seed(semilla)

    if trend=="n":
        # ARIMA(0,1,0) sin deriva
        model_rw = ARIMA(np.zeros(n), order=(0,1,0))
        # params = [sigma^2] --> varianza del ruido
        data = model_rw.simulate(params=[sigma2], random_state=semilla, nsimulations=transitorio+n)[transitorio:]
    elif trend=="t":
        # Paseo aleatorio con deriva (ARIMA(0,1,0) con tendencia lineal)
        model_rw_drift = ARIMA(np.zeros(n), order=(0,1,0), trend="t")
        # params = [pendiente, sigma^2]
        data = model_rw_drift.simulate(params=[pendiente, sigma2], random_state=semilla, nsimulations=transitorio+n)[transitorio:]

    s=5

```

```

# Crear la figura
fig = plt.figure(figsize=(18, 7))

# Subgráfico de la serie temporal
ax1 = fig.add_subplot(2, 1, 1)
ax1.plot(data, color='blue')
ax1.set_title('Serie Temporal Simulada')
ax1.set_xlabel('t')

# Crear una fila de 3 subgráficos para ACF, PACF y periodograma
ax2 = fig.add_subplot(2, 3, 4) # Fila 2, Columna 1
sm.graphics.tsa.plot_acf(data, lags=lags, ax=ax2, title='ACF Estimada', zero=False, auto_ylimits=True)
ax2.set_xlabel('Retardo')
ax2.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax2.grid(axis='x') # Añadir cuadrícula vertical

ax3 = fig.add_subplot(2, 3, 5) # Fila 2, Columna 2
sm.graphics.tsa.plot_pacf(data, lags=lags, ax=ax3, title='PACF Estimada', zero=False, auto_ylimits=True)
ax3.set_xlabel('Retardo')
ax3.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax3.grid(axis='x') # Añadir cuadrícula vertical

ax4 = fig.add_subplot(2, 3, 6) # Fila 2, Columna 3
f, Pxx = signal.welch(data, fs=1, nperseg=256)
ax4.plot(f, Pxx, color='purple')
ax4.set_title('Periodograma Estimado')
ax4.set_xlabel('Frecuencia')
ax4.set_xlim(0, 0.5) # Limitar el eje x a 0.5

plt.tight_layout()
plt.close(fig)
return fig

```

1. Código común para la generación de las 4 figuras

```

# Crear la figura
fig = plt.figure(figsize=(18, 7))

# Subgráfico de la serie temporal
ax1 = fig.add_subplot(2, 1, 1)
ax1.plot(data, color='blue')
ax1.set_title('Serie Temporal Simulada')
ax1.set_xlabel('t')

# Crear una fila de 3 subgráficos para ACF, PACF y periodograma
ax2 = fig.add_subplot(2, 3, 4) # Fila 2, Columna 1
sm.graphics.tsa.plot_acf(data, lags=lags, ax=ax2, title='ACF Estimada', zero=False, auto_ylimits=True)
ax2.set_xlabel('Retardo')
ax2.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax2.grid(axis='x') # Añadir cuadrícula vertical

ax3 = fig.add_subplot(2, 3, 5) # Fila 2, Columna 2
sm.graphics.tsa.plot_pacf(data, lags=lags, ax=ax3, title='PACF Estimada', zero=False, auto_ylimits=True)
ax3.set_xlabel('Retardo')
ax3.xaxis.set_major_locator(ticker.MultipleLocator(s)) # Tics en múltiplos de 's'
ax3.grid(axis='x') # Añadir cuadrícula vertical

ax4 = fig.add_subplot(2, 3, 6) # Fila 2, Columna 3
f, Pxx = signal.welch(data, fs=1, nperseg=256)
ax4.plot(f, Pxx, color='purple')
ax4.set_title('Periodograma Estimado')
ax4.set_xlabel('Frecuencia')
ax4.set_xlim(0, 0.5) # Limitar el eje x a 0.5

```

5.4. Análisis de las raíces de un polinomio (polynomial_roots_table)

Función que muestra las raíces de un polinomio en una tabla junto a su parte real, parte imaginaria, módulo, frecuencia, periodo y multiplicidad.

```
def polynomial_roots_table(coef_polinomio):
    """
    Función que calcula las raíces de un polinomio y presenta sus características en forma de tabla.

    Args:
        coef_polinomio (list): Lista de coeficientes del polinomio, donde el índice representa el grado del término.

    Returns:
        pd.DataFrame: DataFrame que contiene las raíces del polinomio junto a su parte real, parte imaginaria,
            módulo, frecuencia, periodo y multiplicidad.

    Descripción:
        Esta función utiliza la librería SymPy para obtener las raíces de un polinomio definido por sus coeficientes.
        Luego, calcula la parte real e imaginaria de cada raíz, así como su módulo, frecuencia correspondiente
        a la fase de la raíz, periodo asociado a la frecuencia y la multiplicidad de cada raíz. Finalmente,
        se presenta la información en un DataFrame de pandas.
    """
    polinomio = Polynomial(coef_polinomio, symbol='B')
    roots = polinomio.roots()

    # Contar la multiplicidad de las raíces
    unique_roots, counts = np.unique(roots, return_counts=True)

    # Crear listas para cada columna de la tabla
    real_parts = []
    imaginary_parts = []
    moduli = []
    frequencies = []
    periods = []
    multipliers = []

    for root, count in zip(unique_roots, counts):
        real = root.real
        imag = root.imag

        # Calcular módulo
        modulus = np.abs(root)
        moduli.append(modulus)

        # Calcular frecuencia y periodo
        frequency = np.abs(np.angle(root)) / (2*np.pi)
        period = 1/frequency if frequency else 'Inf'

        # Append results
        real_parts.append(real)
        imaginary_parts.append(imag)
        frequencies.append(frequency)
        periods.append(period)
        multipliers.append(count) # Multiplicidad

    # Crear un DataFrame para mostrar la tabla
    table = pd.DataFrame({
        'P. real': real_parts,
        'P. imag.': imaginary_parts,
        'Módulo': moduli,
        'Frecuencia': frequencies,
        'Periodo': periods,
        'Multip.': multipliers
```

```

})

# Ordenar la tabla por la columna 'Frequency' en orden ascendente
tabla = table.sort_values(by='Frecuencia').round(6)
return tabla

```

5.5. Análisis de las raíces de un polinomio (Localizacion_parametros_plot)

Programa que sitúa el par de parámetros de un polinomio de grado 2 respecto del triángulo donde que indica las regiones donde dicho polinomio es invertible.

```

def Localizacion_parametros_plot(parametro1, parametro2, modelo='MA'):
    """
    Genera un gráfico que localiza el par de parámetros de un polinomio de grado 2 en relación con un triángulo,
    indicando las regiones donde dicho polinomio es invertible.

    Args:
        parametro1 (float): Valor del primer parámetro del polinomio.
        parametro2 (float): Valor del segundo parámetro del polinomio.
        modelo (str, opcional): Tipo de modelo a utilizar. Por defecto es 'MA'. Puede ser 'AR' para ajustar las
            representaciones de los parámetros.

    Returns:
        matplotlib.figure.Figure: Objeto Figure que contiene el gráfico generado.
    """
    fig, ax = plt.subplots(figsize=(10, 6))
    ax.set_aspect('equal')

    # Set axis
    xmin, ymin = -2.2, -1.2
    xmax, ymax = -xmin, -ymin
    plt.axis([xmin, xmax, ymin, ymax])

    # Define the Greek letter based on modelo with subscripts
    simb_param_1 = r'$\phi_1$' if modelo == 'AR' else r'$\theta_1$'
    simb_param_2 = r'$\phi_2$' if modelo == 'AR' else r'$\theta_2$'

    # Set axis labels
    ax.set(xticks=[], yticks=[])
    ax.set_xlabel(simb_param_2, fontsize=16)
    ax.xaxis.set_label_position('top')
    ax.set_ylabel(simb_param_1, rotation=0, fontsize=16)
    ax.yaxis.set_label_position('right')

    # Draw (t1, t2) points
    p1 = np.linspace(-2, 2, 100)
    ax.plot(p1, -abs(p1) + 1, c='black', linestyle='--')
    ax.plot(p1, np.full_like(p1, -1), c='lightgray', linestyle='--')
    ax.plot(p1, -(p1**2 / 4), c='black')

    # Fill the region below the parabola and above the base of the triangle
    ax.fill_between(p1, -(p1**2 / 4), -1, where=-(p1**2 / 4) >= -1, color='lightgray', alpha=0.5)

    # Turn normal axes off
    for spine in ['left', 'bottom', 'top', 'right']:
        ax.spines[spine].set_visible(False)

    # Add arrows to represent axes
    axes_arrows = {'arrowstyle': '<|-|>', 'lw': 0.5, 'color': 'gray'} # Hacerlas grises y más finas
    ax.annotate('', xy=(xmin, 0), xytext=(xmax, 0), arrowprops=axes_arrows)
    ax.annotate('', xy=(0, ymin), xytext=(0, ymax), arrowprops=axes_arrows)

```

```

# Label complex region
ax.text(0.09, -0.8, 'Raíces complejas', ha='center', fontsize=14, color='gray')

# Add small marker to y-axis
ax.axhline(y=1.005, xmin=0.495, xmax=0.505, c='black')
ax.text(-0.12, -1.12, '-1', fontsize=10)
ax.text(-0.12, 0.98, '1', fontsize=10)

# Add small markers to x-axis
ax.axvline(x=-2, ymin=0.495, ymax=0.505, c='black')
ax.axvline(x=2, ymin=0.495, ymax=0.505, c='black')
ax.text(-2.12, -0.12, '-2', fontsize=10)
ax.text(1.88, -0.12, '2', fontsize=10)

marker = ax.scatter(parametro1, parametro2, s=100, color='blue', marker='.')
ax.legend([marker], [f'({simb_param_1}={parametro1}, {simb_param_2}={parametro2})'], loc='upper right', fontsize=12)
plt.tight_layout()
plt.close(fig)

return fig

```

5.6. Conversión de un polinomio B^s en un polinomio en B

```

def Seasonal_to_regular_polynomial(coeffs, s):
    """
    Transforma la lista de coeficientes de un polinomio en  $B^s$  en un polinomio en  $B$ :
    """
    ## Crea la lista completa de coeficientes para el polinomio
    lista_coefs = [coeffs[i//s] if i % s == 0 else 0 for i in range(s * len(coeffs) - (s - 1))]
    # Crea y devuelve el polinomio a partir de los coeficientes
    return Polynomial(lista_coefs, symbol='B')

```

5.7. Gráfico región parámetros polinomio grado 2 (RegionParametrica)

Gráfico que muestra las regiones para los pares de coeficientes donde un polinomio de grado dos es invertible. Si se indica que el modelo es 'AR' la letra usada para los parámetros es ϕ , y si se indica 'MA' la letra usada para los parámetros es θ

```

def RegionParametrica(modelo='generico'):
    """
    Dibuja y anota un gráfico que representa regiones paramétricas dependiendo del modelo especificado.

    Args:
        modelo (str): Tipo de modelo a utilizar. Puede ser 'AR', 'MA' o 'generico'.
                     'AR' representa un modelo autorregresivo, 'MA' un modelo de medias móviles y
                     cualquier otro valor utilizará un modelo genérico.

    Returns:
        figura: Un objeto figura que representa el gráfico generado.

    Ejemplo:
        >>> fig = RegionParametrica(modelo='AR')
        >>> plt.show(fig)
    """

```



```

fig, ax = plt.subplots(figsize=(10, 6))
ax.set_aspect('equal')

# Set axis
xmin, ymin = -3, -2
xmax, ymax = -xmin, -ymin
plt.axis([xmin, xmax, ymin, ymax])

# Define the Greek letter based on modelo with subscripts
if modelo == 'AR':
    simb_param_1 = r'$\phi_1$'
    simb_param_2 = r'$\phi_2$'
elif modelo == 'MA':
    simb_param_1 = r'$\theta_1$'
    simb_param_2 = r'$\theta_2$'
else:
    simb_param_1 = r'$\tau_1$'
    simb_param_2 = r'$\tau_2$'

desdolariza = lambda texto: texto.replace('$', '')

# Set axis labels
ax.set(xticks=[], yticks=[])
ax.set_xlabel(simb_param_2, fontsize=16)
ax.xaxis.set_label_position('top')
ax.set_ylabel(simb_param_1, rotation=0, fontsize=16)
ax.yaxis.set_label_position('right')

# Draw (t1, t2) points
p1 = np.linspace(-2, 2, 100)
ax.plot(p1, -abs(p1) + 1, c='black', linestyle='--')
ax.plot(p1, np.full_like(p1, -1), c='lightgray', linestyle='--')
ax.plot(p1, -(p1**2 / 4), c='black')

# Fill the region below the parabola and above the base of the triangle
ax.fill_between(p1, -(p1**2 / 4), -1, where=-(p1**2 / 4) >= -1, color='lightgray', alpha=0.5)

# Turn normal axes off
for spine in ['left', 'bottom', 'top', 'right']:
    ax.spines[spine].set_visible(False)

# Add arrows to represent axes
axes_arrows = {'arrowstyle': '<-|>', 'lw': 0.5, 'color': 'gray'} # Hacerlas grises y más finas
ax.annotate('', xy=(xmin, 0), xytext=(xmax, 0), arrowprops=axes_arrows)
ax.annotate('', xy=(0, ymin), xytext=(0, ymax), arrowprops=axes_arrows)

# Label complex region
ax.text(0.09, -0.8, 'Raíces complejas', ha='center', fontsize=14, color='gray')

# Annotate the plot with equations
plot_arrowsl = {'arrowstyle': '-|>', 'connectionstyle': "arc3, rad=-0.2"}
plot_arrowsr = {'arrowstyle': '-|>', 'connectionstyle': "arc3, rad=0.2"}
ax.annotate('$' + desdolariza(simb_param_1) + '+' + desdolariza(simb_param_2) + '<1$', xy=(0.4, 0.25), xytext=(1.1, 0.4), arrowprops=plot_arrowsr)
ax.annotate('$' + desdolariza(simb_param_1) + '+' + desdolariza(simb_param_2) + '=1$', xy=(0.38, 0.6), xytext=(0.6, 0.8), arrowprops=plot_arrowsr)

ax.annotate('$' + desdolariza(simb_param_2) + '-' + desdolariza(simb_param_1) + '<1$', xy=(-0.4, 0.25), xytext=(-1.7, 0.4), arrowprops=plot_arrowsl)
ax.annotate('$' + desdolariza(simb_param_2) + '-' + desdolariza(simb_param_1) + '=1$', xy=(-0.38, 0.6), xytext=(-1.2, 0.8), arrowprops=plot_arrowsl)

ax.annotate('$' + desdolariza(simb_param_2) + '=-1$', xy=(1.5, -1), xytext=(1.8, -1.3), arrowprops=plot_arrowsl, fontsize=16)

ax.annotate('$' + desdolariza(simb_param_1) + '^2 + 4' + desdolariza(simb_param_2) + '= 0$', xy=(1.0, -0.28), xytext=(1.8, -0.5), arrowprops=plot_arrowsl)
ax.annotate('$' + desdolariza(simb_param_1) + '^2 + 4' + desdolariza(simb_param_2) + '< 0$', xy=(-0.9, -0.6), xytext=(-2.8, -0.8), arrowprops=plot_arrowsl)

# Label cases

```

```

ax.text(.3, 0.25, '1', ha='center', fontsize=16, color='blue')
ax.text(-.3, 0.25, '2', ha='center', fontsize=16, color='blue')
ax.text(-.3, -0.35, '3', ha='center', fontsize=16, color='blue')
ax.text(.3, -0.35, '4', ha='center', fontsize=16, color='blue')

# Add small marker to y-axis
ax.axhline(y=1.005, xmin=0.495, xmax=0.505, c='black')
ax.text(-0.12, -1.12, '-1', fontsize=10)
ax.text(-0.12, 0.98, '1', fontsize=10)

# Add small markers to x-axis
ax.axvline(x=-2, ymin=0.495, ymax=0.505, c='black')
ax.axvline(x=2, ymin=0.495, ymax=0.505, c='black')
ax.text(-2.12, -0.12, '-2', fontsize=10)
ax.text(1.88, -0.12, '2', fontsize=10)

plt.tight_layout()
plt.close(fig)

return fig

```

5.8. Gráfico rango mediana (RangoMediana)

```

def RangoMediana(datos, k=6, ax=None):
    # Inicializar listas para almacenar las medianas y rangos
    medians = []
    ranges = []

    n = len(datos)
    sub_sample_size = n // k
    for i in range(k):
        start = i * sub_sample_size
        end = start + sub_sample_size

        if i == k - 1: # Para el último, incluir los datos sobrantes
            end = n

        sub_sample = datos[start:end]

        # Calcular mediana y rango
        median = np.median(sub_sample)
        range_value = np.max(sub_sample) - np.min(sub_sample)

        medians.append(median)
        ranges.append(range_value)

    # Crear el gráfico rango-mediana en el eje especificado
    if ax is not None:
        ax.scatter(medians, ranges)
        ax.set_title('Gráfico Rango-Mediana')
        ax.set_xlabel('Mediana de Submuestra')
        ax.set_ylabel('Rango de Submuestra (Max - Min)')
        ax.grid()

```
