

Ejercicio de identificación de un modelo ARIMA

Datos

Cargue la serie de datos simulados [f7dcbd-12.gdt](#)



```
open ../../datos/IdentificaEstosARIMA/f7dcbd-12.gdt
```

Tareas a realizar

1. Realice un primer análisis gráfico: haga un gráfico de la serie y un gráfico *rango-media*
2. Determine si es necesario transformar logarítmicamente los datos
3. Determine si es necesario tomar una o más diferencias regulares de la serie
4. Determine si es necesario tomar una diferencia estacional de la serie
5. Encuentre un modelo ARIMA para la serie que sea lo más parsimonioso posible, pero cuyos residuos se puedan considerar *ruido blanco*.
6. Ficheros
 - Versiones: [pdf](#); [html](#).
 - Datos: [f7dcbd-12.gdt](#)
 - Guión de gretl: [P-L06-A-EjercicioIdentificacionARIMA.inp](#)

Primer análisis gráfico

```
gnuplot x --time-series --with-lines --output="SerieEnNiveles.png"  
rmplot x --output="rango-media.png"
```




Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

Estacionariedad en varianza

A la luz de los anteriores gráficos, donde se aprecia que la variabilidad de los datos aumenta con el nivel de la serie, parece necesaria la transformación logarítmica.

Transforme logarítmicamente los datos y grafíquelos

```
logs x
gnuplot l_x --time-series --with-lines --output="SerieEnLogs.png"
rmplot l_x --output="rango-media-enLogs.png"
```



La serie en logs ya parece estacionaria en varianza.

Estacionariedad en media

El gráfico de la serie l_x parece mostrar una evolución en su nivel (una tendencia). Por tanto, parece indicado tomar una diferencia ordinaria.

No obstante, probemos a ajustar un modelo AR(1), probablemente obtendremos un polinomio autoregresivo con una raíz muy próxima a uno (o incluso menor que uno en valor absoluto).

```
AR1 <- arima 1 0 0 ; l_x
```

Function evaluations: 93

Evaluations of gradient: 24

AR1: ARMA, using observations 1985:01-2024:12 (T = 480)

Estimated using AS 197 (exact ML)

Dependent variable: l_x

Standard errors based on Hessian

	coefficient	std. error	z	p-value	
const	2.43628	1.71557	1.420	0.1556	
phi_1	0.998052	0.00178662	558.6	0.0000	***

Mean dependent var	4.117853	S.D. dependent var	1.982703
Mean of innovations	-0.000257	S.D. of innovations	0.124169
R-squared	0.996075	Adjusted R-squared	0.996075
Log-likelihood	317.4684	Akaike criterion	-628.9367
Schwarz criterion	-616.4154	Hannan-Quinn	-624.0149

Real	Imaginary	Modulus	Frequency
------	-----------	---------	-----------

```
-----
AR
Root  1          1.0020      0.0000      1.0020      0.0000
-----
```

AR1 saved

Tal como se anticipaba, la raíz es casi 1. También podemos probar con los test formales de raíz unitaria

Test ADF

```
adf -1 l_x --c --glsl --test-down --perron-qu
```

```
Augmented Dickey-Fuller (GLS) test for l_x
testing down from 17 lags, criterion modified AIC, Perron-Qu
sample size 477
unit-root null hypothesis: a = 1
```

```
test with constant
including 2 lags of (1-L)l_x
model: (1-L)y = b0 + (a-1)*y(-1) + ... + e
estimated value of (a - 1): -0.00213547
test statistic: tau = -1.19526
approximate p-value 0.226
1st-order autocorrelation coeff. for e: -0.013
lagged differences: F(2, 474) = 156.788 [0.0000]
```

El p-valor es elevado, por lo que NO se rechaza la H_0 de que la serie es $I(1)$

Test KPSS

```
kpss -1 l_x
```

KPSS test for l_x

```
T = 480
Lag truncation parameter = 5
Test statistic = 1.77747
```

```
          10%      5%      1%
Critical values: 0.348  0.462  0.742
P-value < .01
```


El p-valor es menor al 1 %, por lo que se rechaza la H_0 de que la serie es $I(0)$.

- observe también el correlograma. ¿Decae exponencialmente? ¿o lo hace linealmente?

Todas las evidencias apuntan a que es necesaria tomar una diferencia ordinaria

Repetición del análisis con la serie diferenciada

```
diff l_x
gnuplot d_l_x --time-series --with-lines --output="SerieLogEnDiferencias.png"
```



El gráfico de la serie transformada no muestra tener una clara tendencia o evolución a largo plazo de su nivel.

Probemos a ajustar un modelo AR a los datos diferenciados

```
ARIMA110 <- arima(1 1 0 ; d_l_x)
```

Function evaluations: 24

Evaluations of gradient: 5

ARIMA110: ARIMA, using observations 1985:03-2024:12 (T = 478)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L) d_l_x

Standard errors based on Hessian

	coefficient	std. error	z	p-value
const	-0.000361014	0.00262948	-0.1373	0.8908
phi_1	-0.755554	0.0299328	-25.24	1.40e-140 ***

Mean dependent var	-0.000553	S.D. dependent var	0.154022
Mean of innovations	0.000017	S.D. of innovations	0.100834
R-squared	0.388386	Adjusted R-squared	0.388386
Log-likelihood	417.9912	Akaike criterion	-829.9825
Schwarz criterion	-817.4736	Hannan-Quinn	-825.0647

	Real	Imaginary	Modulus	Frequency
AR				
Root 1	-1.3235	0.0000	1.3235	0.5000

ARIMA110 saved

El parámetro ϕ_1 está lejos de la unidad (consecuentemente, también lo está la raíz autorregresiva).

Repitamos también los tests formales

Test ADF

```
adf -1 d_l_x --c --glS --test-down --perron-qu
```

Augmented Dickey-Fuller (GLS) test for d_l_x

testing down from 17 lags, criterion modified AIC, Perron-Qu

sample size 468

unit-root null hypothesis: $a = 1$

```
test with constant
including 10 lags of (1-L)d_l_x
model: (1-L)y = b0 + (a-1)*y(-1) + ... + e
estimated value of (a - 1): -0.145647
test statistic: tau = -3.18886
approximate p-value 0.001
1st-order autocorrelation coeff. for e: 0.001
lagged differences: F(10, 457) = 35.578 [0.0000]
```

El p-valor es muy bajo, por lo que se rechaza la H_0 de que la serie es $I(1)$

Test KPSS

```
kpss -1 d_l_x
```

KPSS test for d_l_x

$T = 479$

Lag truncation parameter = 5

Test statistic = 0.542182


	10%	5%	1%
Critical values:	0.348	0.462	0.742
Interpolated p-value	0.039		


El p-valor no es concluyente: NO se rechaza la H_0 de que la serie es $I(0)$ al 1 %, pero sí se rechaza al 5 %. En cualquier caso, **las evidencias apuntan mayoritariamente a que NO es necesario tomar una segunda diferencia ordinaria**

Diferencias estacionales

Observemos el gráfico de la serie diferenciada y su correlograma.

```
corrgram d_l_x 36 --plot="d_l_x_ACF-PACF.png"
```





Ni en el gráfico de la serie se aprecia ninguna pauta estacional, ni en la función de autocorrelación simple las correlaciones correspondientes a los retardos estacionales son significativas (y deberían ser **muy prominentes** si fuera necesaria una diferencia estacional).

Además, si tratamos de ajustar un AR(1) estacional:

```
ARIMA010X100 <- arima(0 1 0 ; 1 0 0 ; l_x) --nc
```

Function evaluations: 15

Evaluations of gradient: 3

ARIMA010X100:

ARIMA, using observations 1985:02-2024:12 (T = 479)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L) l_x

Standard errors based on Hessian

	coefficient	std. error	z	p-value
Phi_1	0.0578266	0.0459270	1.259	0.2080
Mean dependent var	-0.003555	S.D. dependent var	0.124351	
Mean of innovations	-0.003470	S.D. of innovations	0.124062	
R-squared	0.996083	Adjusted R-squared	0.996083	
Log-likelihood	319.9682	Akaike criterion	-635.9364	
Schwarz criterion	-627.5930	Hannan-Quinn	-632.6565	
	Real	Imaginary	Modulus	Frequency
AR (seasonal)				
Root 1	17.2931	0.0000	17.2931	0.0000

ARIMA010X100 saved


constatamos que la estimación del parámetro Φ_1 no es significativa.

Todas las evidencias apuntan a que NO es necesaria tomar ninguna diferencia estacional

Recuerde que los test ADF y KPSS no sirven para determinar si es necesario tomar diferencias estacionales (solo sirven para las diferencias regulares).

Búsqueda de un modelo ARIMA

Observando al ACF y la PACF se aprecia que la ACF decae a una tasa exponencial, y la PACF se trunca tras el segundo retardo, lo cual es compatible con un AR(2).



Por tanto, parece que la serie en logaritmos sigue un modelo ARIMA(2, 1, 0). Veamos si es así:

```
ARIMA210cte <- arima 2 1 0 ; l_x
```

Function evaluations: 27

Evaluations of gradient: 6

ARIMA210cte:

ARIMA, using observations 1985:02-2024:12 (T = 479)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L) l_x

Standard errors based on Hessian

	coefficient	std. error	z	p-value	
const	-0.00612415	0.0144972	-0.4224	0.6727	
phi_1	0.0933620	0.0365714	2.553	0.0107	**
phi_2	0.604952	0.0365965	16.53	2.22e-61	***

Mean dependent var	-0.003555	S.D. dependent var	0.124351
Mean of innovations	0.000230	S.D. of innovations	0.096517
R-squared	0.997634	Adjusted R-squared	0.997629
Log-likelihood	439.7655	Akaike criterion	-871.5310
Schwarz criterion	-854.8442	Hannan-Quinn	-864.9712

		Real	Imaginary	Modulus	Frequency

AR					
Root	1	-1.3652	0.0000	1.3652	0.5000
Root	2	1.2108	0.0000	1.2108	0.0000

ARIMA210cte saved

Los parámetros autorregresivos son significativos y el modulo de las raíces es claramente mayor que la unidad en ambos casos. No obstante, la constante no es significativa.

Reestimemos el modelo sin constante:

```
ARIMA210 <- arima 2 1 0 ; l_x --nc
```

Function evaluations: 21

Evaluations of gradient: 4

ARIMA210: ARIMA, using observations 1985:02-2024:12 (T = 479)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L) l_x

Standard errors based on Hessian

	coefficient	std. error	z	p-value	
phi_1	0.0936419	0.0365721	2.560	0.0105	**
phi_2	0.605180	0.0365994	16.54	2.05e-61	***

Mean dependent var	-0.003555	S.D. dependent var	0.124351
--------------------	-----------	--------------------	----------

Mean of innovations	-0.001626	S.D. of innovations	0.096534
---------------------	-----------	---------------------	----------

R-squared	0.997634	Adjusted R-squared	0.997629
-----------	----------	--------------------	----------

Log-likelihood	439.6762	Akaike criterion	-873.3525
----------------	----------	------------------	-----------

Schwarz criterion	-860.8374	Hannan-Quinn	-868.4326
-------------------	-----------	--------------	-----------

	Real	Imaginary	Modulus	Frequency
AR				
Root 1	-1.3652	0.0000	1.3652	0.5000
Root 2	1.2104	0.0000	1.2104	0.0000


ARIMA210 saved


Análisis de los residuos

Todo parece OK, pero debemos ver el gráfico de los residuos y su correlograma, así como los estadísticos Q de Ljung-Box para constatar que podemos asumir que son la realización de un proceso de ruido blanco. También conviene mirar si tienen distribución gaussiana:

```
series residuos = $uhat
```

```
gnuplot residuos --time-series --with-lines --output="Residuos.png"  
corrgram residuos 15 --plot="residuosACF-PACF.png"
```





```
corrgram residuos 15
```

Autocorrelation function for residuos

***, **, * indicate significance at the 1%, 5%, 10% levels
using standard error $1/T^{0.5}$

LAG	ACF	PACF	Q-stat.	[p-value]
1	-0.0115	-0.0115	0.0643	[0.800]
2	0.0078	0.0077	0.0940	[0.954]
3	-0.0064	-0.0062	0.1135	[0.990]
4	0.0112	0.0110	0.1747	[0.996]
5	0.0218	0.0222	0.4057	[0.995]
6	-0.0419	-0.0416	1.2590	[0.974]
7	0.0250	0.0239	1.5640	[0.980]
8	-0.0067	-0.0054	1.5857	[0.991]
9	-0.0195	-0.0211	1.7719	[0.995]
10	-0.0009	-0.0004	1.7723	[0.998]
11	0.0433	0.0449	2.6954	[0.994]
12	-0.0331	-0.0353	3.2347	[0.994]
13	0.0462	0.0479	4.2881	[0.988]
14	0.0159	0.0178	4.4136	[0.992]
15	0.0652	0.0623	6.5238	[0.970]

El gráfico de los residuos no presenta ninguna estructura reconocible y ninguna autocorrelación es significativa.

Más importante aún, **los correlogramas no muestran ninguna pauta reconocible, se parecen mucho entre sí y los estadísticos Q muestran p-valores muy elevados**, por lo que podemos asumir que estos residuos son “ruido blanco”.

También conviene mirar si los residuos tienen distribución gaussiana:

```
normtest residuos --jbera
```

Test for normality of residuos:

Jarque-Bera test = 5.68514, with p-value 0.0582758

No rechazamos la hipótesis nula de distribución normal ni al 1 % ni al 5 %.

Adicionalmente, si en la ventana del modelo estimado pincha en el menú desplegable **Gráficos -->Espectro con respecto al periodograma espectral** verá que el espectro teórico del modelo se ajusta perfectamente al periodograma de la serie.

Por tanto, podemos concluir que la serie `f7dcbd-12.gdt`, una vez transformada logarítmicamente, sigue un proceso ARIMA(2,1,0) con media cero.

Modelo efectivamente simulado

Veamos si ese es el modelo usado en su simulación. Si miramos la línea 37 del fichero [000-Etiquetas-12.txt](#) que se encuentra en el directorio de donde hemos obtenido los datos encontramos lo siguiente:

```
f7dcbd, logs, mu = 2.5, ar = '(1 - 0.8B)(1 + 0.8B)', ma = '', i = '(1 - B)'
```

Efectivamente, requería la transformación logarítmica. La media era 2,5, (es decir la constante simulada no era cero). El polinomio AR era de grado 2: $\phi = (1 - 0,8B)(1 + 0,8B) = (1 + 0B - 0,64B^2)$, no tenía estructura MA y la serie requería una diferencia regular $(1 - B)$.

Por supuesto que la estimación de los parámetros no coincide exactamente con los parámetros del modelo simulado, pero la identificación del modelo ha coincidido con el modelo simulado.

Ahora escoja al azar nuevas series del [directorio](#) (dispone de centenares de series simuladas con distintos modelos) y practique la identificación hasta que adquiera seguridad.

Sugerencias (son series sin estacionalidad):

- [f7dcbd-4](#)
- [26cb22-4](#)
- [5ebb40-12](#)
- [68f8ea-4](#)
- [44b9b4-4](#)
- [965e60-4](#)

Código completo de la práctica

[P-L06-A-EjercicioIdentificacionARIMA.inp](#)

```
# -----
# Copyright (C) 2025 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
# DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"
```

```

open ../../datos/IdentificaEstosARIMA/f7dcdbd-12.gdt

gnuplot x --time-series --with-lines --output="SerieEnNiveles.png"
rmplot x --output="rango-media.png"

logs x
gnuplot l_x --time-series --with-lines --output="SerieEnLogs.png"
rmplot l_x --output="rango-media-enLogs.png"

AR1 <- arima 1 0 0 ; l_x

outfile --quiet AR1.txt
  AR1 <- arima 1 0 0 ; l_x
end outfile

adf -1 l_x --c --gls --test-down --perron-qu

outfile --quiet test_ADF.txt
  adf -1 l_x --c --gls --test-down --perron-qu
end outfile

kpss -1 l_x

outfile --quiet test_KPSS.txt
  kpss -1 l_x
end outfile

diff l_x
gnuplot d_l_x --time-series --with-lines --output="SerieLogEnDiferencias.png"

ARIMA110 <- arima 1 1 0 ; d_l_x

outfile --quiet ARIMA110.txt
  ARIMA110 <- arima 1 1 0 ; d_l_x
end outfile

adf -1 d_l_x --c --gls --test-down --perron-qu

outfile --quiet test_ADF_en_diff.txt
  adf -1 d_l_x --c --gls --test-down --perron-qu
end outfile

kpss -1 d_l_x

outfile --quiet test_KPSS_en_diff.txt
  kpss -1 d_l_x
end outfile

corrgram d_l_x 36 --plot="d_l_x_ACF-PACF.png"

ARIMA010X100 <- arima 0 1 0 ; 1 0 0 ; l_x --nc

outfile --quiet ARIMA010x100.txt
  ARIMA010X100 <- arima 0 1 0 ; 1 0 0 ; l_x --nc
end outfile

ARIMA210cte <- arima 2 1 0 ; l_x

outfile --quiet ARIMA210cte.txt
  ARIMA210cte <- arima 2 1 0 ; l_x
end outfile

ARIMA210 <- arima 2 1 0 ; l_x --nc

outfile --quiet ARIMA210.txt
  ARIMA210 <- arima 2 1 0 ; l_x --nc
end outfile

```

```
series residuos = $uhat

gnuplot residuos --time-series --with-lines --output="Residuos.png"
corrgm residuos 15 --plot="residuosACF-PACF.png"

corrgm residuos 15

outfile --quiet ResiduosACF-PACF.txt
    corrgm residuos 15 --quiet
end outfile

normtest residuos --jbera

outfile --quiet ContrasteNormalidadResiduos.txt
    normtest residuos --jbera
end outfile
```