

Lección 8.A — Número de viajeros internacionales

Marcos Bujosa

Número de viajeros internacionales

Guión: [P-L08-A-airlinePass.inp](#)

En esta práctica volvemos sobre la primera serie temporal estudiada en el curso: la serie temporal mensual correspondiente al número total de pasajeros (en miles) de vuelos internacionales de una importante aerolínea de EEUU que aparece en manual de Box & Jenkins.

Objetivo

1. Identificar un modelo para la serie temporal
2. Pronosticar los datos correspondientes a los meses del último año de la muestra.

Comencemos cargando los datos:


Archivo -->Abrir datos -->Archivo de muestra y en la pestaña **Gretl** seleccione **bjg**.
o bien teclee en línea de comandos:

```
open bjg
```

Actividad 1 - Gráfico de series temporales

Obtenga la figura de la serie temporal en logaritmos lg.

```
gnuplot lg --time-series --with-lines --output="log_AP.png"
```



Actividad 2 - Identificar un modelo ARIMA para la serie temporal

Analizando los datos de la serie en logs tras una diferencia regular y otra estacional

Ajuste un modelo ARIMA con constante sin parte AR ni parte MA, pero indicando una diferencia regular u otra estacional.

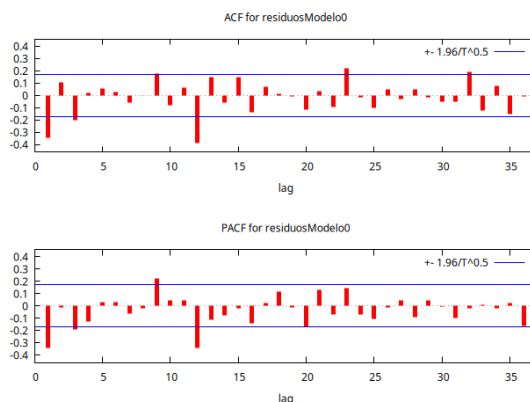
```
arima 0 1 0 ; 0 1 0 ; lg
```

Model 2: ARIMA, using observations 1950:02-1960:12 (T = 131)
 Estimated using least squares (= MLE)
 Dependent variable: (1-L)(1-Ls) lg

	coefficient	std. error	z	p-value
const	0.000290880	0.00400578	0.07261	0.9421
Mean dependent var	0.000291	S.D. dependent var	0.045848	
Mean of innovations	0.000000	S.D. of innovations	0.045848	
R-squared	0.986863	Adjusted R-squared	0.986963	
Log-likelihood	218.4176	Akaike criterion	-432.8353	
Schwarz criterion	-427.0849	Hannan-Quinn	-430.4986	

Y ahora analice el correlograma de los residuos hasta el retardo 36.

```
residuosModelo0 = $uhat
corrgram residuosModelo0 36 --plot="residuosModelo0-ACF-PACF.png"
```



Autocorrelation function for residuosModelo0
 ***, **, * indicate significance at the 1%, 5%, 10% levels
 using standard error 1/T^0.5

LAG	ACF		PACF		Q-stat.	[p-value]
1	-0.3411	***	-0.3411	***	15.5957	[0.000]
2	0.1050		-0.0128		17.0860	[0.000]
3	-0.2021	**	-0.1927	**	22.6478	[0.000]
4	0.0214		-0.1250		22.7104	[0.000]
5	0.0557		0.0331		23.1387	[0.000]
6	0.0308		0.0347		23.2709	[0.001]
7	-0.0556		-0.0602		23.7050	[0.001]
8	-0.0008		-0.0202		23.7050	[0.003]
9	0.1764	**	0.2256	***	28.1473	[0.001]
10	-0.0764		0.0431		28.9869	[0.001]
11	0.0644		0.0466		29.5887	[0.002]
12	-0.3866	***	-0.3387	***	51.4728	[0.000]
13	0.1516	*	-0.1092		54.8664	[0.000]
14	-0.0576		-0.0768		55.3605	[0.000]
15	0.1496	*	-0.0218		58.7204	[0.000]
16	-0.1389		-0.1395		61.6452	[0.000]
17	0.0705		0.0259		62.4045	[0.000]
18	0.0156		0.1148		62.4421	[0.000]
19	-0.0106		-0.0132		62.4596	[0.000]
20	-0.1167		-0.1674	*	64.5984	[0.000]

21	0.0386	0.1324	64.8338	[0.000]
22	-0.0914	-0.0720	66.1681	[0.000]
23	0.2233	**	0.1429	74.2099 [0.000]
24	-0.0184	-0.0673	74.2652	[0.000]
25	-0.1003	-0.1027	75.9183	[0.000]
26	0.0486	-0.0101	76.3097	[0.000]
27	-0.0302	0.0438	76.4629	[0.000]
28	0.0471	-0.0900	76.8387	[0.000]
29	-0.0180	0.0469	76.8943	[0.000]
30	-0.0511	-0.0049	77.3442	[0.000]
31	-0.0538	-0.0964	77.8478	[0.000]
32	0.1957	**	-0.0153	84.5900 [0.000]
33	-0.1224	0.0115	87.2543	[0.000]
34	0.0777	-0.0192	88.3401	[0.000]
35	-0.1525	*	0.0230	92.5584 [0.000]
36	-0.0100	-0.1649 *	92.5767	[0.000]

Fijémonos en los retardos estacionales.

- En la ACF son significativos el 12, pero no el 24 ni el 36.
- En la PACF son significativos el 12 y el 36.

Esto sugiere un truncamiento en la ACF pero no en la PACF. Por tanto, probemos con un MA(1) estacional.

Probando con un MA(1) estacional

```
arima 0 1 0 ; 0 1 1 ; lg
```

Function evaluations: 18

Evaluations of gradient: 6

Model 4: ARIMA, using observations 1950:02-1960:12 (T = 131)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L)(1-Ls) lg

Standard errors based on Hessian

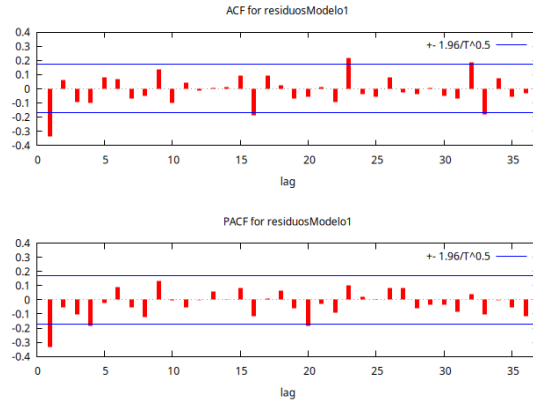
	coefficient	std. error	z	p-value
const	-0.000211216	0.00159988	-0.1320	0.8950
Theta_1	-0.602630	0.0785055	-7.676	1.64e-14 ***

Mean dependent var	0.000291	S.D. dependent var	0.045848
Mean of innovations	0.000883	S.D. of innovations	0.039184
R-squared	0.990288	Adjusted R-squared	0.990288
Log-likelihood	235.7851	Akaike criterion	-465.5701
Schwarz criterion	-456.9445	Hannan-Quinn	-462.0652

	Real	Imaginary	Modulus	Frequency
MA (seasonal)				
Root 1	1.6594	0.0000	1.6594	0.0000

Y ahora analice el correlograma de los residuos hasta el retardo 36.

```
residuosModelo1 = $uhat
corrgram residuosModelo1 36 --plot="residuosModelo1-ACF-PACF.png"
```



Autocorrelation function for residuosModelo1
 ***, **, * indicate significance at the 1%, 5%, 10% levels
 using standard error $1/T^{0.5}$

LAG	ACF		PACF		Q-stat.	[p-value]
1	-0.3340	***	-0.3340	***	14.9506	[0.000]
2	0.0622		-0.0555		15.4738	[0.000]
3	-0.0927		-0.1009		16.6443	[0.001]
4	-0.1026		-0.1869	**	18.0895	[0.001]
5	0.0798		-0.0247		18.9703	[0.002]
6	0.0668		0.0874		19.5929	[0.003]
7	-0.0720		-0.0520		20.3216	[0.005]
8	-0.0524		-0.1208		20.7102	[0.008]
9	0.1372		0.1318		23.3986	[0.005]
10	-0.1011		-0.0066		24.8709	[0.006]
11	0.0427		-0.0509		25.1359	[0.009]
12	-0.0154		-0.0026		25.1707	[0.014]
13	0.0063		0.0596		25.1765	[0.022]
14	0.0143		0.0016		25.2068	[0.033]
15	0.0910		0.0853		26.4505	[0.034]
16	-0.1889	**	-0.1159		31.8589	[0.010]
17	0.0915		0.0086		33.1374	[0.011]
18	0.0247		0.0667		33.2312	[0.016]
19	-0.0697		-0.0584		33.9860	[0.018]
20	-0.0569		-0.1836	**	34.4950	[0.023]
21	0.0111		-0.0261		34.5145	[0.032]
22	-0.0924		-0.0933		35.8782	[0.031]
23	0.2183	**	0.0997		43.5690	[0.006]
24	-0.0349		0.0195		43.7669	[0.008]
25	-0.0556		0.0023		44.2750	[0.010]
26	0.0784		0.0827		45.2958	[0.011]
27	-0.0264		0.0805		45.4123	[0.015]
28	-0.0395		-0.0618		45.6758	[0.019]
29	0.0087		-0.0345		45.6886	[0.025]
30	-0.0518		-0.0332		46.1520	[0.030]
31	-0.0697		-0.0820		46.9978	[0.033]
32	0.1866	**	0.0409		53.1233	[0.011]
33	-0.1789	**	-0.1046		58.8136	[0.004]
34	0.0715		-0.0033		59.7326	[0.004]
35	-0.0582		-0.0541		60.3468	[0.005]
36	-0.0314		-0.1187		60.5276	[0.006]

Si nos fijamos en los retardos estacionales, ninguno es significativo ni en la ACF ni en la PACF. Pasemos a la parte regular del modelo.

Probando con un AR(1) regular (además del MA(1) estacional)

En el correlograma se aprecia que el primer retardo es significativo tanto en la ACF como en la PACF. Con el resto no es fácil detectar una estructura clara; aunque el cuarto retardo de la PACF es significativo.

Probemos tentativamente a añadir un polinomio autoregresivo de orden 1.

```
arima 1 1 0 ; 0 1 1 ; lg
```

Function evaluations: 25

Evaluations of gradient: 8

Model 6: ARIMA, using observations 1950:02-1960:12 (T = 131)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L)(1-Ls) lg

Standard errors based on Hessian

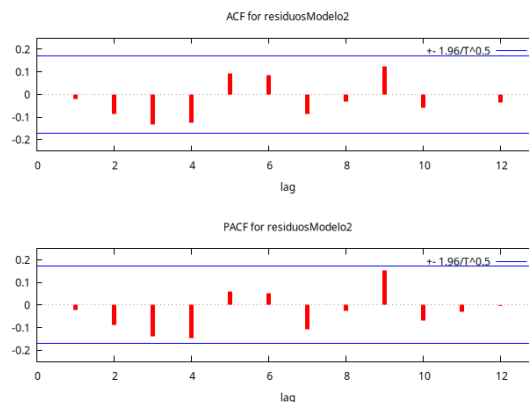
	coefficient	std. error	z	p-value
const	-0.000174550	0.00121017	-0.1442	0.8853
phi_1	-0.339539	0.0821894	-4.131	3.61e-05 ***
Theta_1	-0.562488	0.0748819	-7.512	5.84e-14 ***

Mean dependent var	0.000291	S.D. dependent var	0.045848
Mean of innovations	0.001038	S.D. of innovations	0.036974
R-squared	0.991359	Adjusted R-squared	0.991292
Log-likelihood	243.7523	Akaike criterion	-479.5046
Schwarz criterion	-468.0038	Hannan-Quinn	-474.8313

	Real	Imaginary	Modulus	Frequency
AR				
Root 1	-2.9452	0.0000	2.9452	0.5000
MA (seasonal)				
Root 1	1.7778	0.0000	1.7778	0.0000

Y ahora analice el correlograma de los residuos (puesto que ya no hay restos de estacionalidad, basta con mirar los primeros retardos).

```
residuosModelo2 = $uhat
corrgram residuosModelo2 12 --plot="residuosModelo2-ACF-PACF.png"
```



Autocorrelation function for residuosModelo2
 ***, **, * indicate significance at the 1%, 5%, 10% levels
 using standard error $1/T^{0.5}$

LAG	ACF	PACF	Q-stat.	[p-value]
1	-0.0212	-0.0212	0.0600	[0.806]
2	-0.0874	-0.0879	1.0924	[0.579]
3	-0.1333	-0.1383	3.5113	[0.319]
4	-0.1254	-0.1449 *	5.6682	[0.225]
5	0.0949	0.0613	6.9123	[0.227]
6	0.0856	0.0514	7.9348	[0.243]
7	-0.0846	-0.1055	8.9408	[0.257]
8	-0.0310	-0.0255	9.0773	[0.336]
9	0.1239	0.1549 *	11.2686	[0.258]
10	-0.0585	-0.0697	11.7619	[0.301]
11	-0.0002	-0.0314	11.7619	[0.382]
12	-0.0359	-0.0032	11.9505	[0.450]

Parece que los residuos son ruido blanco. Pero estaba claro el motivo por el que probar con un AR(1) regular en lugar de una MA(1) regular (máxime cuando la PACF tenía un cuarto retardo significativo).

Probemos tentativamente a añadir un polinomio MA de orden 1 (en lugar del polinomio AR).

Probando con un MA(1) regular (además del MA(1) estacional)

```
arima 0 1 1 ; 0 1 1 ; lg
```

Function evaluations: 48

Evaluations of gradient: 13

Model 8: ARIMA, using observations 1950:02-1960:12 (T = 131)

Estimated using AS 197 (exact ML)

Dependent variable: (1-L)(1-Ls) lg

Standard errors based on Hessian

	coefficient	std. error	z	p-value
const	-0.000162569	0.000974395	-0.1668	0.8675
theta_1	-0.402057	0.0896975	-4.482	7.38e-06 ***
Theta_1	-0.557716	0.0731707	-7.622	2.50e-14 ***

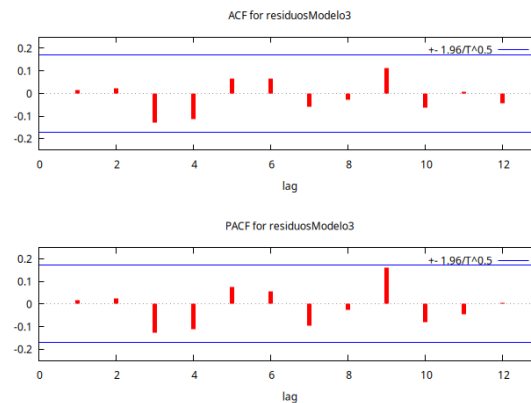
Mean dependent var	0.000291	S.D. dependent var	0.045848
Mean of innovations	0.001240	S.D. of innovations	0.036710
R-squared	0.991478	Adjusted R-squared	0.991412
Log-likelihood	244.7104	Akaike criterion	-481.4207
Schwarz criterion	-469.9199	Hannan-Quinn	-476.7475

	Real	Imaginary	Modulus	Frequency

MA				
Root 1	2.4872	0.0000	2.4872	0.0000
MA (seasonal)				
Root 1	1.7930	0.0000	1.7930	0.0000

Y ahora analice el correlograma de los residuos (puesto que ya no hay restos de estacionalidad, basta con mirar los primeros retardos).

```
residuosModelo3 = $uhat
corrgram residuosModelo3 12 --plot="residuosModelo3-ACF-PACF.png"
```



Autocorrelation function for residuosModelo3
 ***, **, * indicate significance at the 1%, 5%, 10% levels
 using standard error $1/T^{0.5}$

LAG	ACF	PACF	Q-stat.	[p-value]
1	0.0167	0.0167	0.0376	[0.846]
2	0.0245	0.0242	0.1185	[0.942]
3	-0.1276	-0.1285	2.3354	[0.506]
4	-0.1142	-0.1122	4.1246	[0.389]
5	0.0650	0.0765	4.7088	[0.452]
6	0.0671	0.0578	5.3369	[0.501]
7	-0.0580	-0.0967	5.8102	[0.562]
8	-0.0266	-0.0260	5.9104	[0.657]
9	0.1142	0.1619 *	7.7730	[0.557]
10	-0.0637	-0.0807	8.3574	[0.594]
11	0.0083	-0.0432	8.3673	[0.680]
12	-0.0431	0.0050	8.6391	[0.733]

También este modelo arroja residuos con aspecto de ruido blanco. Comparemos qué modelo parece mejor.

Si nos fijamos en la significatividad de los parámetros, en ambos modelos todos los parámetros son significativos excepto la constante (que omitiremos en el futuro).

Pero para este último modelo, los estadísticos Q de Ljung-Box tienen p-valores más altos, el R-cuadrado corregido es mayor y sus criterios de información más bajos.


Por tanto, nos quedaremos con este modelo para hacer la predicción (omitiendo la constante).

Actividad 4 - Previsión para los 12 meses de 1960

Reestimaremos el modelo con datos hasta diciembre de 1959 y haremos la previsión de los meses de 1960.

```
smpl 1949:01 1959:12
arima 0 1 1 ; 0 1 1 ; lg --nc
```

```
dataset addobs 12
fcast 1959:01 1960:12 --plot="prediccion1960.png"
```



Código completo de la práctica

```
# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
# DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).
```

```
string directory = getenv("DIRECTORIO")
set workdir "@directory"

open bjg

gnuplot lg --time-series --with-lines --output="log_AP.png"

arima 0 1 0 ; 0 1 0 ; lg

outfile --quiet Modelo0.txt
    arima 0 1 0 ; 0 1 0 ; lg
end outfile

residuosModelo0 = $uhat
corrgram residuosModelo0 36 --plot="residuosModelo0-ACF-PACF.png"

outfile --quiet CorrelogramaModelo0.txt
    corrgram residuosModelo0 36 --quiet
end outfile

arima 0 1 0 ; 0 1 1 ; lg

outfile --quiet Modelo1.txt
    arima 0 1 0 ; 0 1 1 ; lg
end outfile

residuosModelo1 = $uhat
corrgram residuosModelo1 36 --plot="residuosModelo1-ACF-PACF.png"

outfile --quiet CorrelogramaModelo1.txt
    corrgram residuosModelo1 36 --quiet
end outfile

arima 1 1 0 ; 0 1 1 ; lg

outfile --quiet Modelo2.txt
    arima 1 1 0 ; 0 1 1 ; lg
end outfile

residuosModelo2 = $uhat
corrgram residuosModelo2 12 --plot="residuosModelo2-ACF-PACF.png"

outfile --quiet CorrelogramaModelo2.txt
```



```

    corrgm residuosModelo2 12 --quiet
end outfile

arima 0 1 1 ; 0 1 1 ; lg

outfile --quiet Modelo3.txt
    arima 0 1 1 ; 0 1 1 ; lg
end outfile

residuosModelo3 = $uhat
corrgm residuosModelo3 12 --plot="residuosModelo3-ACF-PACF.png"

outfile --quiet CorrelogramaModelo3.txt
    corrgm residuosModelo3 12 --quiet
end outfile

smp1 1949:01 1959:12
arima 0 1 1 ; 0 1 1 ; lg --nc

dataset addobs 12
fcast 1959:01 1960:12 --plot="prediccion1960.png"

```